

**Весна 2021**

# **Системное программное обеспечение**

Онлайн-лекции

## Лекция №10: **Файлы и работа с файлами**

Доцент, к.т.н. ГОЛЬЦОВ Александр Геннадьевич



# Файлы

- Файлы - это именованные порции данных произвольного размера в долговременной памяти (на диске, магнитной ленте, flash-накопителе).
- Доступ к файлам для программ организуется средствами операционной системы.
- Поддержка файловой системы - функция ОС, "делающая ее Операционной Системой". Согласно негласному правилу, различные комплексы управляющих программ получают право называться ОС, если поддерживают файловую систему.

# Файловая система

- ФС - это набор соглашений, действующих в рамках ОС и определяющих способ хранения, именования и доступа к файлам на носителе.
- ФС в ДОС подразумевает возможность объединения файлов в каталоги (директории), в предшественнице ДОС - CP/M - директорий не было, на носителе (дискете) был просто набор файлов.
- Каждому физическому или логическому диску соответствует том (volume); в каждом томе существует корневая директория и вложенные в нее директории.
- Директория = каталог = папка (папки в Windows)

# Обычные и служебные файлы

- Обычные файлы имеют имя и содержат данные, которые используются различными программами.
- Служебные файлы являются элементами файловой системы и непосредственно обеспечивают ее функционирование.
- Служебные файлы ДОС:
  - директории=каталоги (кроме корневой!)
  - метки тома
- В других ОС дополнительно: история транзакций с файлами, загрузочный сектор, карта свободного места тома и т.п.

# Имена файлов

- Имена файлов и директорий подчиняются правилу 8+3: до 8 символов в имени файла и до 3 символов в расширении.
- Имена файлов при работе с функциями ДОС записываются или в формате "name8.ext", или под имя и расширение отводятся массивы из 8 и 3 символов соответственно, "хвост" имени и расширения в этом случае заполняется пробелами.
- Максимальная длина пути к файлу - 80 символов.

# Путь (path)

- Путь является полным адресом файла в компьютере.
- **На все же это ПУТЬ, а не "адрес файла"!**
- Структура пути: C:\LABS\A-08\LAB3.ASM  
C: - буква диска, может отсутствовать, \ - ссылка на корневой каталог, LABS\, A-08\ - ссылки на подкаталоги, LAB3.ASM - имя файла
- Если не указать диск - отсчет ведется с текущего диска, если не указать корневую директорию (ведущий бэкслэш) - отсчет ведется от текущей директории

# Текущая и домашняя директории<sup>7</sup>

- Домашняя директория программы (home dir) - откуда программа запущена, где лежит ее исполнимый файл.
- Текущая директория (current dir) - директория "по умолчанию", на каждом диске - своя, устанавливается и может меняться в процессе работы программы.
- Текущий диск - тоже может меняться в ходе работы программы.
- При старте программы с предварительным переходом в ее директорию, как правило, текущие диск и директория соответствуют домашней.
- А так - нет (указан полный путь): `c:\labs\lab3.exe`

# Командная строка и управление директориями

- **буква:**, например, **d:** - установить текущий диск (никакие директории не упоминаются!)
- **cd путь** - установить текущую директорию
  - **cd lab1** - в текущей директории найти lab1 и сделать ее текущей
  - **cd \lab1** - сделать текущей директорию lab1, расположенную в корневом каталоге текущего диска
  - **cd d:\lab1** - на диске d: сделать текущей директорию \lab1 в корне, **но это не приводит к смене текущего диска**



# Именование файлов

- В именах файлов допустимы:
  - буквы латинского алфавита
  - цифры
  - подчеркивания, ~
- Недопустимы: ?, \*, запятые, кавычки, пробелы, точки
- Буквы русского или национального алфавита
- **Вообще - не называйте файлы и папки в проекте длинными и русскими именами, даже если это разрешено ОС! Русские имена - для документов пользователя.**

# Длинные имена файлов

- В Windows NT / Windows 95 появляются длинные имена файлов, где допустимы пробелы, точки и прочие вольности.
- Программы DOS, запускаемые в этих ОС, могли работать с такими файлами, используя псевдонимы: имена в формате 8.3, построенные по определенным правилам:

"c:\program files\my dir\file name.txt"



C:\PROGRA~1\MYDIR~1\FILENA~1.TXT

# Чтение и запись

- Файлы подразумевают последовательный доступ.
- В файл можно писать/читать произвольное количество байт за одно обращение.
- Следующая порция записываемой информации помещается за текущей (считываемой - считывается после текущей).
- Текущая позиция - смещение относительно начала файла в байтах. Это логический указатель, связанный с каждым файлом и изменяемый при чтении-записи **или явно**.
- Текущая позиция одна и для чтения, и для записи.
- При чтении/записи ТП смещается к концу файла на размер прочитанного/записанного блока данных.
- **Текущую позицию можно явно менять, организовав таким образом прямой доступ к произвольной части файла.**

# Чтение и запись

- Возможны с одним и тем же файлом в произвольной последовательности во времени.
- Читаем/пишем, начиная с текущей позиции.
- Если в ходе записи выходим за конец файла - файл увеличивается.
- Если в ходе чтения выходим за конец файла - считываем меньшее количество байт, чем заказывали.
- В ЯВУ аналогичные функции зовутся BlockRead / BlockWrite (Паскаль), ReadFile / WriteFile (WinAPI), fread / fwrite (Си).
- Поверх файлов удобно организовывать потоки данных (stream).

# Один байт и целый блок

- Операции чтения/записи в файлы физически выполняются секторами - блоками данных 512 байт.
- Если нужно прочесть один байт, то читается весь сектор, и из него копируется нужная порция данных в качестве результата.
- Если нужно записать один байт, то читается весь сектор, модифицируется и записывается целиком.
- → Читать и писать в файлы побайтно можно, но очень неэффективно, если речь идет про большие порции данных. Идет потеря производительности в сотни раз.

# Свойства файла

- Имя и расширение (8+3)
- Путь (до 80 символов с именем файла, до 64 символов - только каталоги)
- Размер (до 2 Гб)
- Дата изменения
- Атрибуты (набор битов):
  - архивный
  - только чтение
  - системный
  - скрытый
  - директория
  - метка тома

# "Бинарные", "текстовые" и прочие файлы <sup>15</sup>

- Любой файл может рассматриваться как бинарный, т.е. состоящий из байтов информации, которые можно читать-писать в произвольном месте в произвольном количестве.
- Могут существовать дополнительные договоренности:
  - о структуре файла (какие байты в каком месте имеют какое значение)
  - о допустимых значениях байтов ("только буквы, цифры и знаки препинания")
  - о том, какое расширение должно быть у файла, хранящего определенную информацию
- Все эти договоренности - "более высокого уровня", они определяют способ работы с конкретными данными, для хранения которых используется файл, но не механизм доступа к самому файлу.

# Текстовые файлы

- Содержат буквы, цифры и прочие знаки - байты с кодами в диапазоне 32 (пробел)..255.
- Признак конца строки - пара байт CR-LF (коды 13-10, 0D-0Ah)
- Не предназначены (неудобны) для попеременного чтения и записи в один и тот же файл.
- Байты с кодами <32 считаются управляющими. Изначально управляли текстовыми принтерами - печатными машинками.
  - 13 (CR) - возврат каретки, перейти к началу строки
  - 10 (LF) - перевод строки, на строку вниз
  - 9 (Tab) - табуляция, сдвинуть курсор вправо на ближайшую следующую позицию табуляции (кратно 8 или 4)
  - 12 (PG) - следующая страницы, прокрутить лист вниз на множество строк до начала следующей страницы
  - 7 (Bell) - издать звуковой сигнал
  - 8 (BS) - Back Space, забой
  - 27 (Esc) - начало управляющей escape-последовательности
- Символ 26 (EOF, конец файла) служил для контроля передачи данных по линии как высокоуровневый маркер конца данных, не требуется, не нужен, не ставится в файле.



# Принцип организации информации<sup>17</sup> на диске

- На уровне контроллера диска (аппаратно) существуют дорожки и сектора (раньше они были реальными, сейчас - виртуальные).
- ОС выделяет пространство на диске кластерами, 1 кластер = несколько секторов, например  $4K = 8 * 512$
- Каждый кластер свободен или принадлежит какому-то файлу (размер занимаемого файлом места на диске округляется в большую сторону до кратного размеру кластера).
- **Файл = цепочка кластеров**, информация о цепочках (ссылка на следующий кластер) также хранится в служебной области на диске.
- Каталог файлов (директория) - это служебный файл, содержащий имена файлов, даты создания, размеры, атрибуты - **и номера первых кластеров** в цепочках кластеров, представляющих эти файлы.

# Файловая система FAT

Содержимое диска:

Загрузочный сектор	512 байт
Информация файловой системы	512 байт
Резервные сектора	
Таблица размещения файлов 1 (FAT1)	Число кластеров * 4
Таблица размещения файлов 2 (FAT2)	Число кластеров * 4
Корневой каталог	1 кластер
Массив данных	остальные кластеры


Каждый элемент FAT - номер следующего кластера или признак "конец цепочки" или ноль.

Корневой каталог - занимает 1 кластер (не файл, не имеет имени).

Другие каталоги являются файлами.

# Пример: каталог из 3 файлов

FAT



# Работа с файлами: FCB и хэндлы

- FCB (File Control Block) - низкоуровневая структура (37 байт), поддерживаемая "базовой ДОС" (функциями ОС низкого уровня).
- Это наследие CP/M, неудобно, громоздко.
- Ориентировано на работу с файлами **текущего каталога** (в CP/M разбиения на иерархические каталоги не было).
- Функции ДОС высокого уровня работают с хэндлами файлов.
- Хэндл - числовой идентификатор файла, назначается ему при открытии.
- Одновременно можно открыть **до 16 файлов**, включая IN, OUT, AUX и ERR.
- Фраза **FILES=nn** в файле config.sys позволяет увеличить это число до 255.

Смещение	Размер	Назначение
0	1	<i>Диск:</i> 00 = текущий, 01 = <b>A:</b> , 02 = <b>B:</b> и т.д.
1 - 8	8	<i>Имя файла,</i> дополняется пробелами до 8 символов.
9 - 11	3	<i>Расширение файла,</i> дополняется пробелами до 3 символов.
12 - 13	2	<i>Номер текущего блока.</i> Блок содержит 128 записей. Для обращения к конкретной записи используется номер текущего блока и номер текущей записи (байт 32). Первый блок файла имеет номер 0, второй - 1 и т.д. Операция открытия файла устанавливает в данном поле 0.
14 - 15	2	<i>Логический размер записи.</i> Операция открытия устанавливает в этом поле значение 128 (80H). После открытия и перед любой операцией чтения или записи можно устанавливать в данном поле любое требуемое значение длины записи.
16 - 19	4	<i>Размер файла.</i> При создании файла <b>DOS</b> вычисляет и записывает это значение (произведение числа записей на размер записи) в оглавление. Операция открытия выбирает размер файла из оглавления и заносит его в данное поле. Программа может читать значение из этого поля, но не может изменять его.
20 - 21	2	<i>Дата.</i> При создании или последней модификации файла <b>DOS</b> записывает дату в оглавление. Операция открытия выбирает дату из оглавления и заносит ее в данное поле.
22 - 31	10	<i>Зарезервировано.</i>
32	1	<i>Текущий номер записи.</i> Данное поле содержит текущий номер записи (0-127) в текущем блоке. <b>DOS</b> использует текущие значения блока и записи для локализации записи в дисковом файле. Обычно номер начальной записи в данном поле - 0, но его можно заменить на любое значение от 0 до 127.
33 - 36	4	<i>Относительный номер записи.</i> Используется для <b>произвольного доступа</b> к записи при операциях чтения или записи. Данное поле должно содержать относительный номер записи. В случае произвольного доступа <b>DOS</b> автоматически преобразует относительный номер записи в текущие номера блока и записи.

# Доступ через FCB

- Подробно рассматривать не будем.
- Нужно постоянно отслеживать и менять информацию в структуре FCB, заполненной при открытии файла.
- Дополнительно используется буфер DTA (disk transfer area), регистрируемый программой для операций с файлами.
- Функции INT 21 с номерами (задаются в регистре AH):
  - 0Fh - open file
  - 10h - close file
  - 11h - find file
  - 21h - read record
  - 22h - write record
  - 23h - get file size
  - 24h - set position
  - 27h - block read
  - 28h - block write
  - и др., искать по ключевому слову "FCB".

# Доступ через хэндлы

- Примерно соответствует логике организации функций работы с файлами в ЯВУ.
- Переменная файлового типа в ЯВУ является записью, одно из полей - хэндл файла.
- Функции:
  - 3Ch - создать файл (перезаписать пустым)
  - 3Dh - открыть существующий файл (для чтения и записи!)
  - 3Eh - закрыть файл
  - 3Fh - прочесть блок данных из файла
  - 40h - записать блок данных в файл
  - 42h - установить явно текущую позицию чтения-записи
- Ключевое слово для многих подобных функций - "DOS 2+"

# Атрибуты файла

-	-	arc	dir	vol	sys	hid	ro
---	---	-----	-----	-----	-----	-----	----

Биты байта атрибутов:

0: ro - только чтение

1: hid - скрытый

2: sys - системный

3: vol - метка тома

4: dir - подкаталог

5: arc - архивный

Обычный файл имеет атрибут 0 или 20h (arc)



# Основные коды ошибок

- 02 - файл не найден
- 03 - путь не найден
- 04 - слишком много открытых файлов
- 05 - доступ запрещен
- 06 - неверный хэндл
- 16 - попытка удалить каталог как файл
- 18 - нет больше файлов (по условию поиска)

# Создать файл (существующий стирается)

INT 21 - DOS 2+      - CREATE A FILE      WITH  
HANDLE (CREAT)  
    AH = 3Ch  
    CX = attributes      for file  
    DS:DX = address      of ASCIZ filename  
Return:    CF = 1 if error  
            AX = Error Code  
            CF = 0 successful  
            AX = file handle

```
fname1 db 'my.txt',0
handle1 dw ?

.....
mov ah, 3Ch
mov cx,0
mov dx, offset fname1
int 21h
jc ErrorCreate
mov handle1, ax
.....
```

# Открыть файл

INT 21 - DOS 2+ - OPEN DISK FILE WITH HANDLE

AH = 3Dh

AL = access code

0 = Read Only

1 = Write Only

2 = Read/Write

AL bits 7-3 = file-sharing modes (DOS 3.x)

bit 7 = inheritance flag, set for no inheritance

bits 4-6 = sharing mode

000 compatibility mode

001 exclusive (deny all)

010 write access denied (deny write)

011 read access denied (deny read)

100 full access permitted (deny none)

bit 3 = reserved, should be zero

DS:DX = address of ASCIZ filename

Return: CF = 1 if error

AX = Error Code

CF = 0 successful

AX = file handle

```
fname1 db 'my.txt',0
```

```
handle1 dw ?
```

```
.....  
mov ah, 3Dh
```

```
mov al,2 ; r&w
```

```
mov dx, offset fname1
```

```
int 21h
```

```
jc ErrorOpen
```

```
mov handle1, ax  
.....
```

# Заккрыть файл

INT 21 - DOS 2+      - CLOSE    A FILE WITH HANDLE

AH = 3Eh

BX = file handle

Return:    CF = 1 if error

AX = Error Code

# Читать из файла

INT 21 - DOS 2+      - READ FROM FILE WITH  
HANDLE

AH = 3Fh  
BX = file handle  
CX = number of bytes to read  
DS:DX = address of buffer

Return: CF = 1 if error  
          AX = Error Code  
          CF = 0 successful  
          AX = number of bytes read

Алгоритм чтения файла "буферами":

- попытаться читать BufCount, прочесть Count
- обработать Count
- если Count<>BufCount, то закончить, иначе продолжить

bufsize equ 4096

buf db bufsize dup(?)  
handle1 dw ?

.....  
mov ah, 3Fh  
mov bx, handle1  
mov cx, bufsize  
mov dx, offset buf  
int 21h

jc ErrorRead  
; ax = сколько прочлось

.....

# Писать в файл

INT 21 - DOS 2+      - WRITE    TO FILE    WITH  
HANDLE

AH = 40h

BX = file handle

CX = number of bytes to write

DS:DX =    pointer to buffer

Return: CF = 1 if error

AX = Error Code

CF = 0 successful

AX = number of bytes written

Note: if CX is zero, no data is written, and the file is  
truncated or extended to the current position

"Если указать CX=0, то запись данных не производится, а размер файла устанавливается равным текущей позиции (последующее содержимое файла отсекается, если оно есть)."

В ряде ЯВУ такая функция зовется Truncate.

# Переместиться к позиции

INT 21 - DOS 2+ - MOVE FILE READ/WRITE  
 POINTER (LSEEK)

AH = 42h

AL = method value

0 = offset from beginning of file

1 = offset from present location

2 = offset from end of file

BX = file handle

CX:DX = offset in bytes

Return: CF = 1 if error

AX = Error Code

CF = 0 successful

DX:AX = new offset

;Перейти в конец файла  
 pos dd ?

.....  
 mov ah, 42h

mov al,2 ; с конца!

xor cx,cx

xor dx,dx ; dx:cx = 0

int 21h

jc ErrorPos

mov word ptr pos, ax

mov word ptr pos+2, dx

Спасибо за внимание.